

Jakub Nadolny

228079

16 marca 2018

# Algorytm genetyczny

Implementacja i analiza rozszerzonego problemu  
komiwożacza

# Algorytm genetyczny

Idea algorytmu genetycznego została zaczerpnięta z nauk przyrodniczych opisujących zjawiska doboru naturalnego i dziedziczenia. Mechanizmy te polegają na przetrwaniu osobników najlepiej dostosowanych w danym środowisku, podczas gdy osobniki gorzej przystosowane są eliminowane. Z kolei te osobniki, które przetrwają - przekazują informację genetyczną swoim potomkom. Krzyżowanie informacji genetycznej otrzymanej od "rodziców" prowadzi do sytuacji, w której kolejne pokolenia są przeciętnie coraz lepiej dostosowane do warunków środowiska; mamy więc tu do czynienia ze swoistym procesem optymalizacji. W pewnym uproszczeniu możemy przyjąć, że algorytmy genetyczne służą do optymalizacji pewnych funkcji (zwanymi funkcjami przystosowania). Zauważmy jednak, że klasa ich zastosowań jest dużo szersza: algorytmy genetyczne możemy stosować przy dowolnych problemach, dla których uda się skonstruować funkcję oceniającą rozwiązania (funkcja celu). W tym ujęciu wiele problemów można przeformułować w ten sposób, aby stały się zadaniami optymalizacyjnymi.

Źródło : [http://kolos.math.uni.lodz.pl/~archive/Sztuczna\\_inteligencja\\_Klasyczny\\_algorytm\\_genetyczny\\_cz1.pdf](http://kolos.math.uni.lodz.pl/~archive/Sztuczna_inteligencja_Klasyczny_algorytm_genetyczny_cz1.pdf)

## Problem komiwojażera

Nazwa pochodzi od typowej ilustracji problemu, przedstawiającej go z punktu widzenia wędrownego sprzedawcy (komiwojażera): dane jest  $n$  miast, które komiwojażer ma odwiedzić, oraz odległość / cena podróży / czas podróży pomiędzy każdą parą miast. Celem jest znalezienie najkrótszej / najtańszej / najszybszej drogi łączącej wszystkie miasta, zaczynającej się i kończącej się w określonym punkcie. Symetryczny problem komiwojażera polega na tym, że dla dowolnych miast  $A$  i  $B$  odległość z  $A$  do  $B$  jest taka sama jak z  $B$  do  $A$ .

## Zademonstrowania działania algorytmu

Poniższe wykresy pokazują przebieg algorytmów dla pięciu macierzy dystansów, oraz przepływów. W celu selekcji używam modelu turowego z następującymi parametrami :

### Parametry

Populacja	Pokolenia	P. mutacji	Wielkość turnieju	Ilość przebiegów
100	100	20%	10	10

### Wykresy





## Wnioski

Zwiększenie wymiarów matrycy dystansów, oraz przepływu zwiększa czas wykonania algorytmu. Przebiegi algorytmów są podobne do siebie. Na początku najlepszy wynik jest bardzo oddalony od optymalnego, a w następnych pokoleniach zbliża się do niego. Są to wyniki uśrednione z 10 przebiegów każdy. Pojedyncze przebiegi dotarły do wyniku optymalnego, jednak średni wynik - jak widać wyżej - nie znajduje optimum.

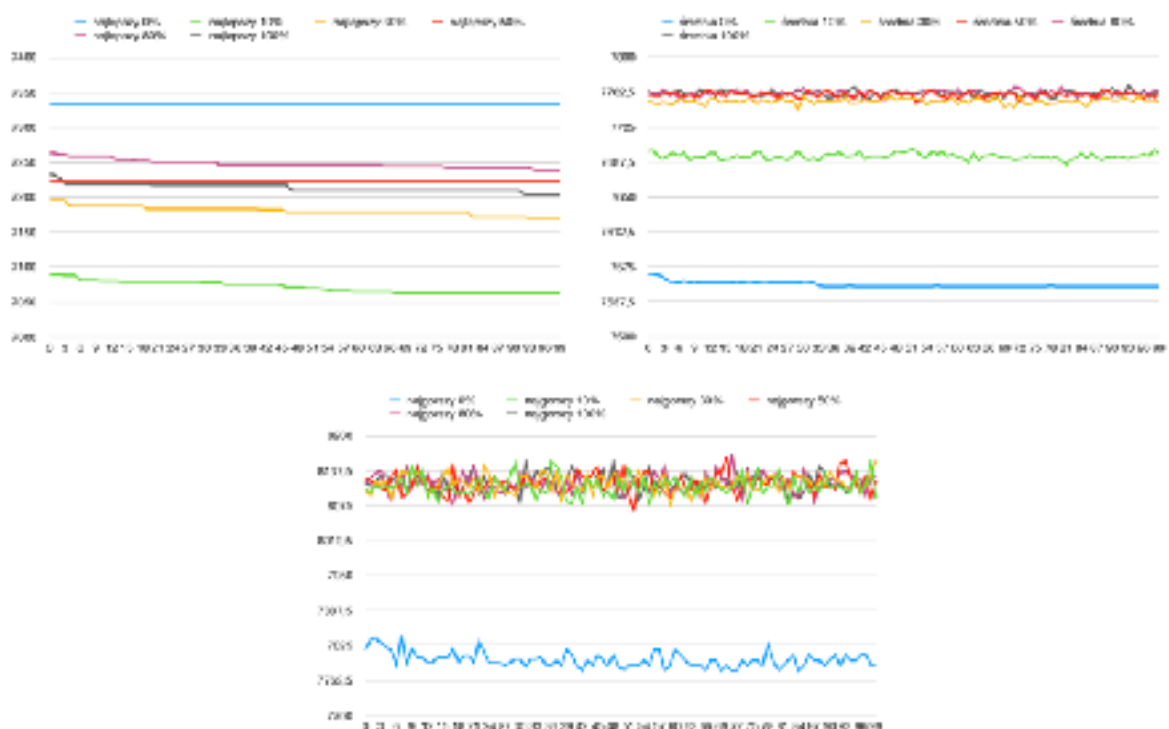
# Prawdopodobieństwo mutacji

W tym ćwiczeniu badam wpływ prawdopodobieństwa mutacji na uzyskane wyniki.

## Parametry

Populacja	Pokolenia	P. mutacji	Wielkość turnieju	Ilość przebiegów
200	100	0, 10, 30, 50, 80, 100%	10	10

## Wykresy



## Wnioski

Analiza wyników ukazuje, że skrajne wartości prawdopodobieństwa mutacji są nieoptymalne. Zbyt małe prawdopodobieństwo sprawia, że algorytm skupia się na ekstremum lokalnym i nie znajduje nowych lepszych rozwiązań. Zbyt duże prawdopodobieństwo sprawia, że najlepsze rozwiązania są mutowane i znikają z populacji. Najlepszy wynik osiągnęła populacja z 10% szansą na mutację genu.


# Prawdopodobieństwo krzyżowania

W tym ćwiczeniu badam wpływ prawdopodobieństwa krzyżowania na uzyskane wyniki.

## Parametry

Populacja	Pokolenia	P. mutacji	Wielkość turnieju	Ilość przebiegów	P. Krzyżowania
200	100	30%	10	10	20,40,60,80,100%

## Wykresy



## Wnioski

Najlepsze wyniki uzyskały przebiegi z 20% i 80% na krzyżowanie. Widać zależność ilości „przełomowych” osobników przy większych prawdopodobieństwach krzyżowania. Zastanawiającym faktem jest duża odległość średniej populacji z 20 i 100% prawdopodobieństwem, od innych średnich. Moim zdaniem wynika to z tego, że w obu populacjach na początku zostały wylosowane bardzo dobre osobniki na początku algorytmu.


# Wielkość populacji

W tym ćwiczeniu badam wpływ ilości osobników w populacji na uzyskane wyniki.

## Parametry

Populacja	Pokolenia	P. mutacji	Wielkość turnieju	Ilość przebiegów
200	100	30%	10	10

## Wyniki



## Wnioski

Wielkość populacji wpłynęła znacząco na czas wykonywania się algorytmu. Im większa populacja tym większa też szansa na dobrego osobnika w puli początkowej, która wpływa znacznie na wyniki końcowe. Mniejsza populacja wymaga dużej mutacji, aby znajdować coraz lepsze rozwiązania (nie zatrzymać się na jednym).

# Liczba pokoleń

W tym ćwiczeniu badam wpływ ilości osobników w populacji na uzyskane wyniki.

## Parametry

Populacja	Pokolenia	P. mutacji	Wielkość turnieju	Ilość przebiegów
200	100	30%	10	10

## Wyniki



## Wnioski

Im większa liczba populacji, tym większy czas trzeba poświęcić na wykonywanie się algorytmu. Jak widać na powyższym wykresie, dłuższa generacja oznacza także większe szanse na znalezienie kolejnego lepszego rozwiązania.



## Różne sposoby selekcji

W tym ćwiczeniu badam wpływ sposobu selekcji osobników w populacji na uzyskane wyniki.

### Parametry

Populacja	Pokolenia	P. mutacji	Wielkość turnieju	Ilość przebiegów
200	100	30%	10	10

### Wyniki



### Wnioski

Wybrałem do tego porównania dwa sposoby selekcji - turniejowy, oraz ruletkowy. Sposób turniejowy dawał lepsze wyniki. Jest to prawdopodobnie spowodowane faktem, iż wynik fitness function każdego osobnika jest bardzo zbliżony. W skrócie - różnice między kosztami najlepszego i najgorszego osobnika jest bardzo niewielka.


## Porównanie z algorytmem nieewolucyjnym

W tym ćwiczeniu porównuję algorytm genetyczny z selekcją turową, oraz algorytm losowy przenoszący najlepszy wynik do następnego losowania

### Parametry

Populacja	Pokolenia	P. mutacji	Wielkość turnieju	Ilość przebiegów
100	100	20%	10	10

### Wyniki



### Wnioski

Algorytm losowy, który wykonałem losuje populacje i z nich zapamiętuje najlepsze wyniki. Porównuję go z algorytmem turowym. Algorytm turowy ma więcej skoków - spowodowanych mutacją, oraz krzyżowaniem w którym mogą powstać nowe mocne chromosomy. Największą różnicę widać na wykresie średnich wartości. Pomimo zbliżonych wartości najgorszych osobników, wartość średnia znacznie odbiega w stronę mniejszego kosztu na wykresie algorytmu turniejowego.